

PAM 驱动机器人行走策略训练方案对比

教师-学生蒸馏网络 vs. 直接 RL 训练 · 技术讨论总结报告

一、背景与核心问题

PAM（气动人工肌肉，Pneumatic Artificial Muscle）驱动的机器人在仿真与实物之间存在显著的模型差距（sim-to-real gap）：仿真中可使用理想化的 PAM 数学模型，而实物 PAM 存在滞回、非线性、摩擦等难以精确建模的特性。

核心问题：在 PAM 驱动机器人的行走策略训练中，教师-学生蒸馏网络与直接在仿真中加入 PAM 模型训练 RL 策略哪种方案更优？两者的优缺点各是什么？

二、教师-学生网络的核心动机（澄清）

T-S 蒸馏的核心优势并非“快速收敛”或“依赖专家数据”，而是解决**训练-部署时观测域不匹配**的问题。

维度	教师网络 (Teacher)	学生网络 (Student)
训练环境	仿真，可访问特权信息	仿真
部署环境	✗ 无法部署（需特权信息）	✓ 可直接部署
观测来源	GT 位姿、理想模型参数等	真实传感器、本体感知
PAM 场景	理想 PAM 模型（无滞回）	含误差/噪声的 PAM 模型

T-S 解决的本质是“训练时能用的信息、部署时拿不到”这一**观测域迁移**问题。对于 PAM 机器人，将理想模型放在教师端、含误差模型放在学生端，是非常合理的应用场景。

三、方案 A：教师-学生蒸馏网络 (T-S)

3.1 工作流程

Step 1 教师阶段：在仿真中以**理想 PAM 模型**（精确力-压强关系、无滞回）训练行走策略，获得高质量轨迹与动作分布。

Step 2 学生阶段：学生网络以**含误差 PAM 模型**（加入滞回、噪声、参数不确定性）训练，以教师的输出作为监督信号进行模仿/蒸馏。

Step 3 实物迁移：学生网络只使用可在实物上获取的传感器输入，直接迁移到实物 PAM 机器人。

3.2 优点

✓ **显著降低 sim-to-real gap：**学生网络天然在“降级”的模拟器上训练，已暴露于 PAM 误差，实物迁移更稳定。

- ✓策略鲁棒性强：教师提供高质量参考轨迹，学生在此基础上学习容错，避免从零探索。
- ✓模块化：教师与学生可独立迭代，更换 PAM 型号时只需重训学生端。
- ✓适合 PAM 特性建模困难的场景：无需对实物 PAM 精确建模，学生端只需"足够接近"即可。
- ✓可扩展至多任务/多步骤：教师-学生框架天然支持分层能力迁移。

3.3 缺点

- ✗训练流程复杂：需要两阶段训练，超参数调优工作量翻倍。
- ✗总训练时间更长：先训教师、再蒸馏学生，整体耗时高于单一策略。
- ✗教师瓶颈效应：若教师策略本身质量不足，学生的上限也会受限。
- ✗蒸馏目标设计有难度：动作蒸馏 vs. 隐状态蒸馏 vs. 轨迹模仿，选择不当会导致学生性能退化。
- ✗PAM 误差模型仍需标定：学生端的含误差 PAM 模型需要一定的实物辨识数据作为基础。

四、方案 B：直接在仿真中加入 PAM 模型训练 RL 策略

4.1 工作流程

在仿真环境（如 MuJoCo / Isaac Gym）中直接嵌入 PAM 的物理/数学模型（含滞回、非线性等），以标准 RL 算法（PPO、SAC 等）训练单一端到端行走策略，期望策略能自主学会补偿非线性特性。

4.2 优点

- ✓流程简洁：单一训练循环，无需设计蒸馏损失，调试链路短。
- ✓端到端优化：策略直接针对 PAM 动力学优化，不存在蒸馏误差累积。
- ✓理论上界更高：若 PAM 模型足够准确，策略可充分利用所有动力学特性。
- ✓无教师瓶颈：性能上限仅由仿真模型精度和 RL 算法决定。

4.3 缺点

- ✗严重依赖 PAM 建模精度：若仿真 PAM 模型与实物差距大，直接迁移失败概率高（尤其是滞回特性）。
- ✗探索效率低：PAM 非线性导致奖励稀疏，RL 收敛慢，可能需要大量 Domain Randomization。
- ✗策略脆弱性：过度拟合仿真中的 PAM 特性，对实物参数漂移（温度、老化）鲁棒性差。
- ✗PAM 建模本身极难：精确的 PAM 滞回模型（如 Preisach 模型）嵌入仿真计算代价高，且辨识需要大量实物实验。
- ✗调参周期长：奖励函数与 PAM 动力学耦合，一旦模型变更需重新调参。

五、综合对比

对比维度	方案 A：T-S 蒸馏	方案 B：直接 RL
训练复杂度	高（两阶段）	低（单阶段）
对 PAM 建模精度依赖	低（学生端容忍误差）	极高（模型需精确）

Sim-to-Real 鲁棒性	✔ 强	⚠ 弱（模型差距大时）
收敛速度	学生端快（有教师引导）	慢（PAM 非线性）
策略上限	受教师质量约束	理论更高（模型准时）
PAM 更换适应性	✔ 只需重训学生端	✗ 需完整重训
调试难度	蒸馏损失设计复杂	奖励函数设计复杂
适用场景	PAM 模型不确定性大，实物迁移优先	PAM 模型已精确标定，仿真计算资源充足

六、推荐与结论

对于 PAM 驱动机器人行走这一具体场景，综合讨论结论如下：

① 优先推荐方案 A（T-S 蒸馏）

PAM 的滞回与非线性特性使精确建模极为困难，而 T-S 框架允许在理想模型下训练高质量教师，再让学生在降级模型下适配，天然匹配"训练时用理想模型、部署时面对真实误差"的需求。这与 ANYmal 等四足机器人的成功范式高度一致。

② 方案 B 的适用前提

仅当团队已完成精确的 PAM 辨识（如基于 Preisach 或神经网络的滞回模型），且仿真计算资源充足时，直接 RL 方案才具有竞争力。

③ 混合方案（推荐进阶）

在方案 A 的学生端引入 Domain Randomization（随机化 PAM 参数），进一步提升对实物参数漂移的鲁棒性，是目前最稳健的实物迁移路径。